

El Arañador: buscador de dinosaurios

Portada

Campo	Valor
Buscador	PaleoBusca (nombre propuesto, por confirmar)
Título	El Arañador: recolección web de información sobre dinosaurios
Institución	Instituto Tecnológico de Costa Rica, Escuela de Computación
Curso	Recuperación de Información Textual
Profesor	Aurelio Sanabria
Integrantes	Luis Diego Delgado Muñoz · Diego Alonso Mora Montes · Marlon Iván Badilla Mora
Fecha de entrega	1 de octubre de 2026
Periodo	II Semestre 2026

En la versión final esta tabla se reemplaza por la portada formal con el logo del TEC, igual a la de la Tarea02.

1. Necesidad de información

PaleoBusca responde preguntas sobre dinosaurios y paleontología con texto de fuentes confiables: museos, universidades, servicios geológicos y medios de divulgación científica. La colección está en inglés, porque ahí se concentra la divulgación científica de calidad sobre el tema y todas las semillas están en ese idioma.

1.1 Tema y características de la información

El tema central son los dinosaurios no avianos y la ciencia que los estudia. La información buscada tiene estas características:

- **Textual y explicativa:** artículos, fichas de especies, glosarios y lecciones, no catálogos de productos ni foros.
- **De fuente verificable:** museos de historia natural, universidades, parques nacionales, servicios geológicos y revistas de divulgación.
- **Mayormente estable:** un artículo sobre el Cretácico cambia poco; las noticias de descubrimientos nuevos sí se actualizan.
- **Rica en nombres propios y términos técnicos:** géneros (*Tyrannosaurus*, *Triceratops*), periodos (Triásico, Jurásico, Cretácico) y conceptos (fosilización, extinción K-Pg).

1.2 Subtemas de interés

- Especies y clasificación: terópodos, saurópodos, ornitisquios; fichas por género.
- Tiempo geológico: Triásico, Jurásico y Cretácico, y cómo se datan las rocas.
- Fósiles: cómo se forman, tipos de fósil, dónde se encuentran.
- Extinción masiva del Cretácico-Paleógeno y sus hipótesis.
- Dinosaurios y aves: plumas, evolución y parentesco.
- Anatomía, alimentación, comportamiento y hábitat.
- Descubrimientos, yacimientos y paleontólogos.

1.3 Tipo de consultas esperadas

Siguiendo la clasificación de Broder (2002), predominan las consultas **informativas**; hay pocas navegacionales y casi ninguna transaccional.

Tipo	Ejemplo de consulta	Qué espera el usuario
Informativa factual	<i>when did Stegosaurus live</i>	Un dato puntual: periodo y antigüedad
Informativa explicativa	<i>how do fossils form</i>	Un artículo que explique el proceso

Comparativa	<i>T. rex vs Spinosaurus size</i>	Datos de dos especies en un mismo texto
Por característica	<i>feathered dinosaurs</i>	Lista de especies o artículo temático
Navegacional	<i>Natural History Museum dino directory</i>	Llegar a una página o sitio concreto

1.4 Colectivo al que se dirige

Se propone el siguiente colectivo, a validar por el grupo:

Aspecto	Caracterización
Rango etario	12 a 25 años: estudiantes de secundaria y de primeros años universitarios; secundariamente, docentes y aficionados adultos
Contexto socioeconómico	Acceso a internet y a un dispositivo, en contexto escolar o universitario; nivel medio de inglés lector
Uso principal	Tareas escolares, proyectos de ciencias, estudio de biología y geología, curiosidad personal
Nivel de conocimiento	Básico a intermedio: necesitan explicaciones claras, pero también fuentes citables para trabajos académicos
Consultas típicas	<i>what killed the dinosaurs, largest dinosaur ever, difference between Jurassic and Cretaceous, how are fossils dated</i>

Este perfil explica la mezcla de semillas: BBC Bitesize y NHM apuntan a estudiantes, mientras UCMP Berkeley y el NPS aportan profundidad para trabajos universitarios.

2. Políticas de arañado

El arañador aplica 15 políticas agrupadas según la clasificación de Castillo (2004): **selección, revisita, cortesía y paralelización**. Cada política indica qué hace, por qué responde a la necesidad de información del colectivo y qué metadatos requiere. Los valores numéricos son iniciales y se ajustarán según el comportamiento real del arañador.

[embed: node/423759e1-4b3d]

Las páginas que superan el filtro temático devuelven sus enlaces a la frontera; las demás se descartan y quedan registradas en la bitácora.

2.1 Políticas de selección

Deciden qué páginas se descargan y cuáles enlaces se siguen.

P1. Lista blanca de dominios confiables

- **Descripción:** solo se descargan páginas de dominios aprobados: los de las semillas y otros de museos, universidades (.edu, .ac.uk), entidades de gobierno (.gov) y revistas de divulgación científica. Un dominio nuevo descubierto entra a la lista si su primera página supera el filtro temático (P3).
- **Justificación:** el colectivo usa la información para tareas y trabajos académicos, así que necesita fuentes citables. Así se evitan foros, tiendas de juguetes y sitios de pseudociencia.
- **Metadatos:** `dominio`, `origen_dominio` (semilla o descubierto), `fecha_aprobacion`.

P2. Filtro por tipo de contenido

- **Descripción:** antes de descargar se descartan URLs con extensiones de imagen, audio, video, CSS, JS o comprimidos. Tras la respuesta solo se acepta `Content-Type text/html`, `text/plain` o `application/pdf`. Del HTML se extrae únicamente el texto visible y se eliminan menús, scripts y estilos.
- **Justificación:** el repositorio debe ser texto plano limpio. Los PDF se incluyen porque muchos artículos científicos sobre paleontología solo existen en ese formato y son útiles para estudiantes universitarios.
- **Metadatos:** `content_type`, `extension`, `tamano_bytes_original`.

P3. Filtro temático (arañado enfocado)

- **Descripción:** cada página recibe un puntaje de relevancia según la frecuencia de términos de un diccionario del tema (dinosaur, fossil, Jurassic, Cretaceous, paleontology, nombres de géneros, etc.). Se guarda solo si el puntaje supera un umbral, y solo se siguen sus enlaces si es relevante.
- **Justificación:** es la técnica de *focused crawling* de Chakrabarti et al. (1999). Evita que el arañador se desvíe hacia temas generales de los sitios, como noticias de política en la BBC, que no sirven al colectivo.

- **Metadatos:** `puntaje_tematico`, `terminos_encontrados`, `es_relevante`.

P4. Priorización de la frontera

- **Descripción:** la cola de URLs pendientes es una cola de prioridad. Una URL hereda el puntaje de la página donde apareció y suma puntos si el texto del enlace (anchor text) contiene términos del tema. Se descargan primero las más prometedoras.
- **Justificación:** Cho, García-Molina y Page (1998) muestran que ordenar la frontera por importancia obtiene antes las páginas valiosas. Si el arañador se detiene antes de tiempo, lo descargado es lo más útil.
- **Metadatos:** `prioridad`, `anchor_text`, `url_padre`.

P5. Profundidad máxima

- **Descripción:** no se siguen enlaces a más de 6 saltos desde la semilla correspondiente.
- **Justificación:** el contenido temático se concentra cerca de las semillas. El límite evita trampas de arañas como calendarios infinitos o paginaciones sin fin.
- **Metadatos:** `profundidad`, `semilla_origen`.

P6. Normalización de URLs y control de visitados

- **Descripción:** toda URL se normaliza antes de encolarla: host en minúsculas, sin fragmento `#`, sin parámetros de rastreo (`utm_*`, `fbclid`), sin puerto por defecto y rutas relativas resueltas. Se guarda en un conjunto de URLs vistas y no se encola dos veces.
- **Justificación:** sigue las reglas de normalización del RFC 3986. Sin ella, la misma página se descargaría varias veces y se inflaría el repositorio con copias inútiles. El script `extraer_links.py` de la Tarea02 ya elimina fragmentos y duplicados.
- **Metadatos:** `url_original`, `url_normalizada`.

P7. Eliminación de contenido duplicado

- **Descripción:** se calcula el hash SHA-256 del texto limpio. Si el hash ya existe, el documento no se guarda.
- **Justificación:** una misma nota de prensa o ficha suele publicarse en varias URLs. Los duplicados no aportan información nueva y distorsionan las estadísticas de frecuencia de palabras.
- **Metadatos:** `hash_sha256`, `duplicado_de`.

P8. Longitud mínima del texto

- **Descripción:** se descartan documentos con menos de 150 palabras de texto limpio.
- **Justificación:** las páginas cortas suelen ser índices, menús o páginas de error, sin valor para responder las consultas del colectivo.
- **Metadatos:** `num_palabras`.

2.2 Política de revisita

P9. Revisita condicional

- **Descripción:** durante la construcción del repositorio cada URL se descarga una sola vez. En corridas posteriores se usa GET condicional con `If-Modified-Since` y `If-None-Match`, y se re-descarga solo si el servidor indica cambios. Las páginas de noticias se revisitan con mayor frecuencia que las fichas de especies.
- **Justificación:** Cho y García-Molina (2003) muestran que conviene visitar según la frecuencia de cambio de cada página. El contenido sobre dinosaurios es mayormente estable, pero los descubrimientos recientes interesan al colectivo.
- **Metadatos:** `fecha_descarga`, `last_modified`, `etag`, `tipo_pagina` (noticia o estable).

2.3 Políticas de cortesía

P10. Respeto de robots.txt

- **Descripción:** antes de visitar un host se descarga y guarda en caché su `robots.txt`. Ninguna URL prohibida se descarga, y si el archivo declara `Crawl-delay`, ese valor se respeta.
- **Justificación:** es el estándar del Protocolo de Exclusión de Robots (RFC 9309). Los sitios de museos y universidades son servicios públicos que no deben sobrecargarse.
- **Metadatos:** `robots_permitido`, `crawl_delay`, `fecha_robots`.

P11. Retardo por servidor

- **Descripción:** como máximo una conexión simultánea por host y al menos 1,5 s entre peticiones al mismo host (o el `Crawl-delay`, si es mayor). Varios hosts se descargan en paralelo.
- **Justificación:** es el esquema de colas por host del arañador Mercator (Heydon y Najork, 1999). Permite paralelismo sin saturar un solo servidor.
- **Metadatos:** `host`, `ultima_peticion_host`.

P12. Cuota por dominio

- **Descripción:** ningún dominio puede aportar más del 15 % de los documentos del repositorio. Al alcanzar la cuota, sus URLs pendientes pierden prioridad.
- **Justificación:** la especificación pide no descargar todo de un solo sitio. Además, el colectivo se beneficia de perspectivas y niveles de profundidad distintos.
- **Metadatos:** `documentos_por_dominio`.

P13. Identificación honesta y conexiones seguras

- **Descripción:** el arañador se identifica con un User-Agent propio, como `PaleoBuscaBot/1.0 (+correo del grupo)`, y verifica los certificados SSL.
- **Justificación:** permite a los administradores saber quién los visita y contactar al grupo. Es un cambio respecto al script de la Tarea02, que se hacía pasar por Chrome y desactivaba la verificación SSL.

- **Metadatos:** `user_agent`.

P14. Manejo de errores y reintentos

- **Descripción:** tiempo de espera de 10 s por petición y hasta 3 reintentos con espera exponencial (2, 4 y 8 s). Ante los códigos 429 o 503 se respeta el encabezado `Retry-After`. Los errores 4xx se registran y no se reintentan.
- **Justificación:** evita insistir sobre un servidor con problemas y hace que el arañador no se detenga ante fallos puntuales de red.
- **Metadatos:** `codigo_http`, `intentos`, `error`.

2.4 Política de paralelización

P15. Descarga concurrente con hilos y bitácora

- **Descripción:** un grupo de 8 hilos trabajadores (`ThreadPoolExecutor`) toma URLs de una frontera compartida y segura para hilos. Cada descarga se registra en una bitácora con fecha, hilo, URL, host, código HTTP, decisión (guardado o descartado) y motivo.
- **Justificación:** la rúbrica exige hilos y descarga concurrente. La bitácora demuestra el recorrido de la araña entre sitios y permite explicar cada decisión en la defensa.
- **Metadatos:** `hilo`, `timestamp`, `decision`, `motivo`.

2.5 Metadatos almacenados

Cada documento guardado genera un registro en una base SQLite con estos campos:

Campo	Tipo	Política que lo usa
id	entero	Todas
url_original, url_normalizada	texto	P6
url_padre, anchor_text, semilla_origen	texto	P4, P5
dominio, host	texto	P1, P11, P12

profundidad	entero	P5
prioridad, puntaje_tematico	real	P3, P4
content_type, tamano_bytes_original	texto, entero	P2
codigo_http, intentos, error	entero, entero, texto	P14
fecha_descarga, last_modified, etag	fecha, texto	P9
titulo	texto	Estadísticas e índice
num_palabras	entero	P8 y estadísticas
hash_sha256	texto	P7
robots_permitido	booleano	P10
ruta_archivo_txt	texto	Repositorio

2.6 Dónde se implementa cada política

Propuesta de módulos del arañador propio en Python, para ubicar cada política en la defensa:

Módulo	Función	Políticas
--------	---------	-----------

<code>frontera.py</code>	Cola de prioridad y conjunto de URLs vistas	P4, P5, P6, P12
<code>filtros.py</code>	Dominios permitidos, extensiones y tipo de contenido	P1, P2
<code>relevancia.py</code>	Diccionario de términos y cálculo del puntaje	P3
<code>cortesia.py</code>	Caché de robots.txt y colas por host	P10, P11
<code>descargador.py</code>	Peticiones HTTP, reintentos, GET condicional y User-Agent	P9, P13, P14
<code>extractor.py</code>	HTML o PDF a texto limpio y extracción de enlaces	P2, P8
<code>almacen.py</code>	Hash, SQLite y archivos .txt	P7, metadatos
<code>arana.py</code>	Hilos trabajadores y bitácora	P15

2.7 Alcance y volumen del repositorio

La meta es de al menos 10 GB de texto limpio, lo que equivale a unos 1 500 millones de palabras. Los sitios de divulgación sobre dinosaurios no alcanzan ese volumen por sí solos. Por eso el filtro temático (P3) acepta también paleontología general, geología histórica y evolución, y la lista blanca (P1) incluye repositorios de literatura científica de acceso abierto, que aportan textos largos y de alta calidad para el colectivo universitario.

3. Estadísticas del repositorio

Pendiente: se completa cuando el arañador termine. Los valores se calculan con un script sobre la carpeta de archivos .txt y la base SQLite.

Métrica	Valor
Tamaño total del texto limpio (GB)	
Cantidad de documentos	
Cantidad total de palabras	
Palabras distintas (vocabulario)	
Dominios distintos	
Documentos descartados (duplicados, fuera de tema, cortos)	
<u>Aquí irá la curva de frecuencia de palabras de toda la colección: rango contra frecuencia en escala log-log. Se espera que siga aproximadamente la ley de Zipf, es decir, una recta de pendiente cercana a -1.</u>	

4. URLs semilla

El arañador parte de 10 URLs de 8 dominios distintos, tomadas de la Tarea02. Combinan divulgación escolar y contenido académico, en línea con el colectivo.

#	URL	Institución	Tipo
1	nhm.ac.uk/discover/what-are-dinosaurs.html	Natural History Museum, Londres	Museo

2	nhm.ac.uk/discover/dino-directory.html	Natural History Museum, Londres	Museo
3	bgs.ac.uk/discovering-geology/fossils-and-geological-time/fossils/	British Geological Survey	Servicio geológico
4	bbc.co.uk/bitesize/articles/zt3ntrd	BBC Bitesize	Educación escolar
5	ucmp.berkeley.edu/diapsids/dinosaur.html	UC Museum of Paleontology, Berkeley	Universidad
6	australian.museum/learn/australia-over-time/fossils/how-do-fossils-form/	Australian Museum	Museo
7	nhmu.utah.edu/articles/exploring-dinosaurs-z	Natural History Museum of Utah	Museo universitario
8	nps.gov/subjects/fossils/dinosaurs.htm	US National Park Service	Gobierno
9	nps.gov/dino/learn/nature/dinosaurs-of-dinosaur.htm	Dinosaur National Monument, NPS	Gobierno
10	discovermagazine.com/what-are-fossils-and-where-are-they-found-the-most-45694	Discover Magazine	Divulgación

La URL 4 se usa sin el fragmento #zjhws82, según la política P6. La URL 10 aparece cortada en la Tarea02 y debe verificarse antes de la corrida.

Bibliografía

- Berners-Lee, T., Fielding, R. y Masinter, L. (2005). *Uniform Resource Identifier (URI): Generic Syntax*. RFC 3986. IETF.
- Broder, A. (2002). A taxonomy of web search. *ACM SIGIR Forum*, 36(2), 3–10.
- Castillo, C. (2004). *Effective Web Crawling*. Tesis doctoral, Universidad de Chile.
- Chakrabarti, S., van den Berg, M. y Dom, B. (1999). Focused crawling: a new approach to topic-specific Web resource discovery. *Computer Networks*, 31(11–16), 1623–1640.
- Cho, J. y García-Molina, H. (2003). Effective page refresh policies for Web crawlers. *ACM Transactions on Database Systems*, 28(4), 390–426.
- Cho, J., García-Molina, H. y Page, L. (1998). Efficient crawling through URL ordering. *Computer Networks and ISDN Systems*, 30(1–7), 161–172.
- Heydon, A. y Najork, M. (1999). Mercator: A scalable, extensible Web crawler. *World Wide Web*, 2(4), 219–229.
- Koster, M., Illyes, G., Zeller, H. y Sassman, L. (2022). *Robots Exclusion Protocol*. RFC 9309. IETF.
- Manning, C. D., Raghavan, P. y Schütze, H. (2008). *Introduction to Information Retrieval*, cap. 20: Web crawling and indexes. Cambridge University Press.