



Instituto Tecnológico de Costa Rica
Escuela de Computación
Recuperación de Información Textual

Proyecto 1: El Arañador (PaleoBusca)

Profesor:
Aurelio Sanabria

Estudiantes:

-

Luis Diego Delgado Muñoz
Diego Alonso Mora Montes
Marlon ivan Badilla Mora

II Semestre 2026

1. Necesidad de información

PaleoBusca responde preguntas sobre dinosaurios y paleontología con texto de fuentes confiables: museos, universidades, servicios geológicos y medios de divulgación científica. La colección está en inglés, porque ahí se concentra la divulgación científica de calidad sobre el tema y todas las semillas están en ese idioma.

1.1 Tema y características de la información

El tema central son los dinosaurios no avianos y la ciencia que los estudia. La información buscada tiene estas características:

- **Textual y explicativa:** artículos, fichas de especies, glosarios y lecciones, no catálogos de productos ni foros.
- **De fuente verificable:** museos de historia natural, universidades, parques nacionales, servicios geológicos y revistas de divulgación.
- **Mayormente estable:** un artículo sobre el Cretácico cambia poco; las noticias de descubrimientos nuevos sí se actualizan.
- **Rica en nombres propios y términos técnicos:** géneros (*Tyrannosaurus*, *Triceratops*), periodos (Triásico, Jurásico, Cretácico) y conceptos (fosilización, extinción K-Pg).

1.2 Subtemas de interés

- Especies y clasificación: terópodos, saurópodos, ornitisquios; fichas por género.
- Tiempo geológico: Triásico, Jurásico y Cretácico, y cómo se datan las rocas.
- Fósiles: cómo se forman, tipos de fósil, dónde se encuentran.
- Extinción masiva del Cretácico-Paleógeno y sus hipótesis.
- Dinosaurios y aves: plumas, evolución y parentesco.
- Anatomía, alimentación, comportamiento y hábitat.
- Descubrimientos, yacimientos y paleontólogos.

1.3 Tipo de consultas esperadas

Siguiendo la clasificación de Broder (2002), predominan las consultas **informativas**; hay pocas navegacionales y casi ninguna transaccional.

Tipo	Ejemplo de consulta	Qué espera el usuario
Informativa factual	<i>when did Stegosaurus live</i>	Un dato puntual: periodo y antigüedad

Informativa explicativa	<i>how do fossils form</i>	Un artículo que explique el proceso
Comparativa	<i>T. rex vs Spinosaurus size</i>	Datos de dos especies en un mismo texto
Por característica	<i>feathered dinosaurs</i>	Lista de especies o artículo temático
Navegacional	<i>Natural History Museum dino directory</i>	Llegar a una página o sitio concreto

1.4 Colectivo al que se dirige

Aspecto	Caracterización
Rango etario	12 a 25 años: estudiantes de secundaria y de primeros años universitarios; secundariamente, docentes y aficionados adultos
Contexto socioeconómico	Acceso a internet y a un dispositivo, en contexto escolar o universitario; nivel medio de inglés lector
Uso principal	Tareas escolares, proyectos de ciencias, estudio de biología y geología, curiosidad personal
Nivel de conocimiento	Básico a intermedio: necesitan explicaciones claras, pero también fuentes citables para trabajos académicos
Consultas típicas	<i>what killed the dinosaurs, largest dinosaur ever, difference between Jurassic and Cretaceous, how are fossils dated</i>

Este perfil explica la mezcla de semillas: BBC Bitesize y NHM apuntan a estudiantes, mientras UCMP Berkeley y el NPS aportan profundidad para trabajos universitarios. Wikipedia y las revistas de acceso abierto (PLOS, Nature, Copernicus, Frontiers) se agregaron después para dar volumen y profundidad.

2. Políticas de arañado

El arañador aplica 15 políticas agrupadas según la clasificación de Castillo (2004): **selección, revisita, cortesía y paralelización**. Cada política indica qué hace, por qué responde a la necesidad de información del colectivo y qué metadatos requiere. Los valores numéricos se calibraron con corridas reales; cada cambio respecto al diseño inicial se indica en su política.

Las páginas que superan el filtro temático devuelven sus enlaces a la frontera; las demás se descartan y quedan registradas en la bitácora.

2.1 Políticas de selección

Deciden qué páginas se descargan y cuáles enlaces se siguen.

P1. Lista blanca de dominios confiables

- **Descripción:** solo se descargan páginas de dominios aprobados: los de las semillas y otros de museos, universidades (.edu, .ac.uk), entidades de gobierno (.gov) y revistas de divulgación científica. Un dominio descubierto se evalúa con hasta 5 páginas, no con una sola: con una se rechazaron 349 dominios (Harvard, Cornell, Bristol, NASA) porque la primera página era una portada. También se descartan URLs de tiendas (*shop.*, */store/*, */cart*).
- **Justificación:** el colectivo usa la información para tareas y trabajos académicos, así que necesita fuentes citables. Así se evitan foros, tiendas de juguetes y sitios de pseudociencia.
- **Metadatos:** *dominio*, *origen_dominio* (semilla o descubierto), *fecha_aprobacion*, *estado* (aprobado, rechazado, sin evaluar).

P2. Filtro por tipo de contenido

- **Descripción:** antes de descargar se descartan URLs con extensiones de imagen, audio, video, CSS, JS o comprimidos. Tras la respuesta solo se acepta *Content-Type text/html*, *text/plain* o *application/pdf*. Del HTML se extrae únicamente el texto visible y se eliminan menús, scripts y estilos. Además de menús, scripts y estilos se eliminan fichas laterales, referencias, cajas de navegación y categorías (bloques de MediaWiki).
- **Justificación:** el repositorio debe ser texto plano limpio. Los PDF se incluyen porque muchos artículos científicos sobre paleontología solo existen en ese formato y son útiles para estudiantes universitarios.
- **Metadatos:** *content_type*, *extension*, *tamano_bytes_original*.

P3. Filtro temático (arañado enfocado)

- **Descripción:** cada página recibe un puntaje de relevancia según la frecuencia de términos de un diccionario del tema (dinosaur, fossil, Jurassic, Cretaceous, paleontology, nombres de géneros, etc.). Se guarda solo si el puntaje supera un umbral (8 aciertos ponderados por cada 1000 palabras; con 4 entraban tiendas de museos y artículos de biología ajenos al tema), y solo se siguen sus enlaces si es relevante. Una página con muy poco texto, 10 o más enlaces y el tema en su título o URL se trata como índice: no se guarda, pero sus enlaces se siguen.
- **Justificación:** es la técnica de *focused crawling* de Chakrabarti et al. (1999). Evita que el arañador se desvíe hacia temas generales de los sitios, como noticias de política en la BBC, que no sirven al colectivo.
- **Metadatos:** `puntaje_tematico`, `terminos_encontrados`, `es_relevante`.

P4. Priorización de la frontera

- **Descripción:** la cola de URLs pendientes es una cola de prioridad. Una URL hereda el puntaje de la página donde apareció y suma puntos si el texto del enlace (anchor text) contiene términos del tema. Se descargan primero las más prometedoras. Las páginas con más de 300 enlaces, como un artículo de Wikipedia, solo encolan los enlaces cuyo anchor o URL menciona el tema. Los nombres de género cuentan por su terminación (-saurus, -raptor, -ceratops).
- **Justificación:** Cho, García-Molina y Page (1998) muestran que ordenar la frontera por importancia obtiene antes las páginas valiosas. Si el arañador se detiene antes de tiempo, lo descargado es lo más útil.
- **Metadatos:** `prioridad`, `anchor_text`, `url_padre`.

P5. Profundidad máxima

- **Descripción:** no se siguen enlaces a más de 6 saltos desde la semilla correspondiente. Se excluye una lista de trampas de araña: buscadores con filtros, páginas de login, descargas de adjuntos, URLs con token o sesión y bases de datos de fichas.
- **Justificación:** el contenido temático se concentra cerca de las semillas. El límite evita trampas de arañas como calendarios infinitos o paginaciones sin fin.
- **Metadatos:** `profundidad`, `semilla_origen`.

P6. Normalización de URLs y control de visitados

- **Descripción:** toda URL se normaliza antes de encolarla: host en minúsculas, sin fragmento #, sin parámetros de rastreo (`utm_*`, `fbclid`), parámetros ordenados alfabéticamente, sin parámetros de orden y vista (`sortOrder`, `resultView`), sin puerto por defecto y rutas relativas resueltas. Se guarda en un conjunto de URLs vistas y no se encola dos veces.
- **Justificación:** sigue las reglas de normalización del RFC 3986. Sin ella, la misma página se descargaría varias veces y se inflaría el repositorio con copias inútiles. El script `extraer_links.py` de la Tarea02 ya elimina fragmentos y duplicados.
- **Metadatos:** `url_original`, `url_normalizada`.

P7. Eliminación de contenido duplicado

- **Descripción:** se calcula el hash SHA-256 del texto limpio. Si el hash ya existe, el documento no se guarda.
- **Justificación:** una misma nota de prensa o ficha suele publicarse en varias URLs. Los duplicados no aportan información nueva y distorsionan las estadísticas de frecuencia de palabras.
- **Metadatos:** `hash_sha256`, `duplicado_de`.

P8. Longitud mínima del texto

- **Descripción:** se descartan documentos con menos de 150 palabras de texto limpio.
- **Justificación:** las páginas cortas suelen ser índices, menús o páginas de error, sin valor para responder las consultas del colectivo.
- **Metadatos:** `num_palabras`.

2.2 Política de revisita

P9. Revisita condicional

- **Descripción:** durante la construcción del repositorio cada URL se descarga una sola vez. En corridas posteriores se usa GET condicional con `If-Modified-Since` y `If-None-Match`, y se re-descarga solo si el servidor indica cambios. Las páginas de noticias se revisitan con mayor frecuencia que las fichas de especies.
- **Justificación:** Cho y García-Molina (2003) muestran que conviene visitar según la frecuencia de cambio de cada página. El contenido sobre dinosaurios es mayormente estable, pero los descubrimientos recientes interesan al colectivo.
- **Metadatos:** `fecha_descarga`, `last_modified`, `etag`, `tipo_pagina` (noticia o estable).

2.3 Políticas de cortesía

P10. Respeto de robots.txt

- **Descripción:** antes de visitar un host se descarga y guarda en caché su `robots.txt`. Ninguna URL prohibida se descarga, y si el archivo declara `Crawl-delay`, ese valor se respeta. También se respetan las etiquetas meta robots `noindex/nofollow`. Si `robots.txt` no se puede leer, se asume prohibido.
- **Justificación:** es el estándar del Protocolo de Exclusión de Robots (RFC 9309). Los sitios de museos y universidades son servicios públicos que no deben sobrecargarse.
- **Metadatos:** `robots_permitido`, `crawl_delay`, `fecha_robots`.

P11. Retardo por servidor

- **Descripción:** como máximo una conexión simultánea por host y al menos 1,5 s entre peticiones al mismo host (o el `Crawl-delay`, si es mayor). Varios hosts se descargan en paralelo. El retardo se cuenta desde que termina la petición anterior.

- **Justificación:** es el esquema de colas por host del arañador Mercator (Heydon y Najork, 1999). Permite paralelismo sin saturar un solo servidor.
- **Metadatos:** `host`, `ultima_peticion_host`.

P12. Cuota por dominio

- **Descripción:** ningún dominio puede aportar más del 15 % de los documentos del repositorio. Al alcanzar la cuota, sus URLs pendientes pierden prioridad. La cuota se aplica después de 500 documentos guardados, porque el primer documento ya da 100 % a su dominio.
- **Justificación:** la especificación pide no descargar todo de un solo sitio. Además, el colectivo se beneficia de perspectivas y niveles de profundidad distintos.
- **Metadatos:** `documentos_por_dominio`.

P13. Identificación honesta y conexiones seguras

- **Descripción:** el arañador se identifica con un User-Agent propio, como `PaleoBuscaBot/1.0 (+correo del grupo)`, y verifica los certificados SSL.
- **Justificación:** permite a los administradores saber quién los visita y contactar al grupo. Es un cambio respecto al script de la Tarea02, que se hacía pasar por Chrome y desactivaba la verificación SSL.
- **Metadatos:** `user_agent`.

P14. Manejo de errores y reintentos

- **Descripción:** tiempo de espera de 10 s por petición y hasta 3 reintentos con espera exponencial (2, 4 y 8 s). Ante los códigos 429 o 503 se respeta el encabezado `Retry-After`. Los errores 4xx se registran y no se reintentan. Las redirecciones no se siguen automáticamente: el destino se trata como un enlace nuevo y pasa por P1, P5, P6 y robots.txt.
- **Justificación:** evita insistir sobre un servidor con problemas y hace que el arañador no se detenga ante fallos puntuales de red.
- **Metadatos:** `codigo_http`, `intentos`, `error`.

2.4 Política de paralelización

P15. Descarga concurrente con hilos y bitácora

- **Descripción:** un grupo de 32 hilos trabajadores (`ThreadPoolExecutor`) toma URLs de una frontera compartida y segura para hilos. Cada descarga se registra en una bitácora con fecha, hilo, URL, host, código HTTP, decisión (guardado o descartado) y motivo. El diseño inicial proponía 8 hilos: en la corrida de prueba había 44 hosts con URLs pendientes y 8 hilos solo atendían 8 a la vez; con 32 el ritmo se duplicó. La cortesía por host no cambió.
- **Justificación:** la rúbrica exige hilos y descarga concurrente. La bitácora demuestra el recorrido de la araña entre sitios y permite explicar cada decisión en la defensa.
- **Metadatos:** `hilo`, `timestamp`, `decision`, `motivo`.

2.5 Metadatos almacenados

La base SQLite (datos/arana.db) tiene 4 tablas: documentos (un registro por documento guardado), urls (todas las URLs conocidas y su estado, para poder reanudar), dominios (lista blanca) y robots (robots.txt por host). Los campos principales son:

Campo	Tipo	Política que lo usa
id	entero	Todas
url_original, url_normalizada	texto	P6
url_padre, anchor_text, semilla_origen	texto	P4, P5
dominio, host	texto	P1, P11, P12
profundidad	entero	P5
prioridad, puntaje_tematico	real	P3, P4
content_type, tamano_bytes_original	texto, entero	P2
codigo_http, intentos, error	entero, entero, texto	P14
fecha_descarga, last_modified, etag	fecha, texto	P9
titulo	texto	Estadísticas e índice
num_palabras	entero	P8 y estadísticas
hash_sha256	texto	P7
robots_permitido	booleano	P10
ruta_archivo_txt	texto	Repositorio

terminos_encontrados, es_relevante	texto, booleano	P3
tipo_pagina	texto	P9
tamano_bytes_texto	entero	Estadísticas
estado, motivo, duplicado_de (tabla urls)	texto, texto, entero	P7, P15 y reanudación

2.6 Dónde se implementa cada política

Módulos del arañador propio en Python y las políticas que implementa cada uno. Son 5 en vez de los 8 del diseño inicial, siguiendo la arquitectura vista en clase (calendarizador, descargador y almacén):

Módulo	Función	Políticas
<code>calendarizador.py</code>	Frontera con cola de prioridad y colas por host: qué URLs entran, en qué orden y cuándo se puede pedir a cada host	P1, P4, P5, P6, P11, P12
<code>descargador.py</code>	Peticiones HTTP, reintentos, GET condicional, User-Agent y robots.txt	P2, P9, P10, P13, P14
<code>procesamiento.py</code>	Normalización de URLs, HTML o PDF a texto limpio, enlaces, puntaje temático y hash	P2, P3, P6, P7, P8
<code>almacen.py</code>	SQLite, archivos .txt y estado para reanudar	P7, P9, metadatos
<code>arana.py</code>	Hilos trabajadores, flujo completo por URL y bitácora	P15

2.7 Alcance y volumen del repositorio

La meta era 10 GB de texto limpio y el repositorio del arañador propio cerró en 0,343 GB. El contenido temático de las semillas se agotó en las primeras horas: de 4 376 documentos guardados en la primera hora se pasó a 240 en la sexta. La cortesía pone un techo de 40 páginas por minuto por host, y al final casi toda la cola pendiente era de un solo host (Wikipedia). Solo el 4,6 % de las URLs procesadas terminó como documento. El volumen lo dieron los artículos largos: los PDF son el 4,7 % de los documentos y el 29 % del texto. Por

eso el filtro temático (P3) acepta también paleontología general, geología histórica y evolución, y la lista blanca (P1) incluye Wikipedia y revistas de acceso abierto (PLOS, Nature, Copernicus, Frontiers).

3. Estadísticas del repositorio

Valores al cierre de las corridas, calculados con un script sobre los archivos .txt y la base de datos de cada arañador.

Arañador

Métrica	Valor
Tamaño total del texto limpio (GB)	0.343 GB
Cantidad de documentos	29,406
Cantidad total de palabras	49,575,911
Palabras distintas (vocabulario)	460,523
Dominios distintos	208
Documentos descartados (duplicados, fuera de tema, cortos)	605,577


Descartes. En total se conocieron 672 235 URLs y se descartaron 605 577: trampas de araña 413 185, fuera de tema 97 292, redirecciones 47 715, muy cortas 22 610, prohibidas por robots.txt 6 152, errores HTTP o de red 6 124, duplicadas 6 036, tipo de contenido no aceptado 3 861 y noindex 2 407. Quedaron 37 252 pendientes.

Tipos de contenido. 27 910 documentos HTML (242,1 MB), 1 380 PDF (99,4 MB) y 116 de texto plano (1,0 MB). La media es de 1 678 palabras por documento.

Dominios con más documentos. wikipedia.org 9 496 documentos (32,3 %), berkeley.edu 2 217 (7,5 %), sciencedaily.com 2 094 (7,1 %), plos.org 1 726 (5,9 %), nature.com 1 342 (4,6 %), bbc.co.uk 1 151 (3,9 %), nhm.ac.uk 1 063 (3,6 %), copernicus.org 957 (3,3 %), nps.gov 931 (3,2 %) y usgs.gov 823 (2,8 %). Los otros 198 dominios suman 7 606 documentos (25,9 %). Por volumen de texto los mayores son plos.org (64,1 MB), wikipedia.org (60,1 MB) y nature.com (33,7 MB).

Arañador Scrapy

Métrica	Valor
Tamaño total del texto limpio (GB)	0.310 GB
Cantidad de documentos	42,148
Cantidad total de palabras	47,871,401
Palabras distintas (vocabulario)	470,973
Dominios distintos	1,734
Documentos descartados (duplicados, fuera de tema, cortos)	1,051,677



Curva de frecuencia de palabras del arañador propio (rango contra frecuencia, escala log-log). Sigue la ley de Zipf: entre los rangos 10 y 10 000 la pendiente ajustada es $-1,12$, cerca del -1 teórico. Las palabras más frecuentes son palabras vacías del inglés (the 3 000 825, of 1 949 724, and 1 491 045); las primeras de contenido son del tema: species (170 865, rango 19), formation (135 189), fossil (120 473) y cretaceous (78 419). Después del rango 10 000 la curva cae más rápido que la recta ideal, por la cola de nombres científicos y términos que aparecen una o dos veces.

4. URLs semilla

El arañador propio parte de 27 URLs: las 10 de la Tarea02 (tabla siguiente) y 17 de volumen, verificadas una por una con verificar_dominios.py (responden 200, robots.txt las permite y tienen texto del tema). Combinan divulgación escolar y contenido académico, en línea con el colectivo.

#	URL	Institución	Tipo
1	nhm.ac.uk/discover/what-are-dinosaurs.html	Natural History Museum, Londres	Museo
2	nhm.ac.uk/discover/dino-directory.html	Natural History Museum, Londres	Museo
3	bgs.ac.uk/discovering-geology/fossils-and-geological-time/fossils/	British Geological Survey	Servicio geológico
4	bbc.co.uk/bitesize/articles/zt3ntrd	BBC Bitesize	Educación escolar
5	ucmp.berkeley.edu/diapsids/dinosaur.html	UC Museum of Paleontology, Berkeley	Universidad
6	australian.museum/learn/australia-over-time/fossils/how-do-fossils-form/	Australian Museum	Museo
7	nhmu.utah.edu/articles/exploring-dinosaurs-z	Natural History Museum of Utah	Museo universitario

8	nps.gov/subjects/fossils/dinosaurs.htm	US National Park Service	Gobierno
9	nps.gov/dino/learn/nature/dinosaurs-of-dinosaur.htm	Dinosaur National Monument, NPS	Gobierno
10	discovermagazine.com/what-are-fossils-and-where-are-they-found-the-most-45694	Discover Magazine	Divulgación

La URL 4 se usa sin el fragmento #zjhws82, según la política P6. La URL 10 (Discover Magazine) responde 403 a los robots: queda registrada como error en la bitácora y no se evade el bloqueo (P13).

Semillas de volumen. en.wikipedia.org/wiki/Category:Dinosaurs, en.wikipedia.org/wiki/Dinosaur y simple.wikipedia.org/wiki/Dinosaur (Wikipedia, solo en inglés); journals.plos.org/plosone/browse/paleontology, nature.com/subjects/palaeontology, frontiersin.org/journals/earth-science y cuatro revistas de Copernicus (jm., fr., se. y cp.copernicus.org); sciencedaily.com/news/fossils_ruins/dinosaurs/, phys.org/tags/dinosaur/ y sciencenews.org/topic/paleontology (divulgación); fieldmuseum.org, geology.utah.gov, kgs.ku.edu y geolsoc.org.uk (museo y servicios geológicos).

Documentos por semilla. Category:Dinosaurs de Wikipedia 12 341, simple.wikipedia.org 2 325, ScienceDaily 2 247, NHM what-are-dinosaurs 2 237, PLOS 1 685, UCMP Berkeley 1 347, NPS fossils 1 094 y NPS Dinosaur National Monument 913. Una semilla con pocos documentos no significa que su sitio aportó poco: si otra semilla llegó antes a las mismas páginas, quedan a nombre de la primera.

Candidatas descartadas en la verificación. amnh.org, biodiversitylibrary.org, naturalhistory.si.edu, MDPI y Royal Society (responden 403 a los robots); palaeo-electronica.org y peerj.com (dependen de JavaScript y casi no entregan texto); app.pan.pl (certificado SSL inválido, que P13 exige verificar).

Bibliografía

- Berners-Lee, T., Fielding, R. y Masinter, L. (2005). *Uniform Resource Identifier (URI): Generic Syntax*. RFC 3986. IETF.
- Broder, A. (2002). A taxonomy of web search. *ACM SIGIR Forum*, 36(2), 3–10.
- Castillo, C. (2004). *Effective Web Crawling*. Tesis doctoral, Universidad de Chile.
- Chakrabarti, S., van den Berg, M. y Dom, B. (1999). Focused crawling: a new approach to topic-specific Web resource discovery. *Computer Networks*, 31(11–16), 1623–1640.
- Cho, J. y García-Molina, H. (2003). Effective page refresh policies for Web crawlers. *ACM Transactions on Database Systems*, 28(4), 390–426.
- Cho, J., García-Molina, H. y Page, L. (1998). Efficient crawling through URL ordering. *Computer Networks and ISDN Systems*, 30(1–7), 161–172.
- Heydon, A. y Najork, M. (1999). Mercator: A scalable, extensible Web crawler. *World Wide Web*, 2(4), 219–229.
- Koster, M., Illyes, G., Zeller, H. y Sassman, L. (2022). *Robots Exclusion Protocol*. RFC 9309. IETF.
- Manning, C. D., Raghavan, P. y Schütze, H. (2008). *Introduction to Information Retrieval*, cap. 20: Web crawling and indexes. Cambridge University Press.